

Universidad de Guadalajara

Centro Universitario de Guadalajara

Licenciatura en Inteligencia Artificial y Ciencia de los Datos

**Reporte técnico de resultados de JAPI para proyección de ventas
diarias**

Angel E. Moreno, Paulo A. Jiménez, Irving G. Robles y Juan P. Estrada

Guadalajara, Jalisco
mayo, 2026

Índice general

0.1. Introducción	2
0.2. Objetivos	3
0.2.1. Objetivo General	3
0.2.2. Objetivos Específicos	3
0.3. Metodología	3
0.3.1. Arquitectura del Repositorio y Estructura del Proyecto	4
0.3.2. Capa de resultados	6
0.3.3. Adquisición y Modelado de Datos	6
0.3.4. Análisis Exploratorio de Datos	10
0.3.5. Limpieza y Normalización	13
0.3.6. Ingeniería de Características	28
0.3.7. Machine Learning, Deep Learning y Modelos Estadísticos Clásicos	29
0.4. Resultados	47
0.4.1. Comparativa de Implementaciones	47
0.4.2. Hallazgos y Posibles Mejoras	47
0.5. Conclusiones	48
0.5.1. Propuesta de Valor e Implementación Operativa	48

0.1. Introducción

El entorno competitivo actual en el sector comercial exige que las organizaciones adopten enfoques analíticos avanzados para optimizar la toma de decisiones estratégicas, particularmente en la gestión de inventarios y la planificación financiera.

En este contexto se sitúa Urvet de México, una organización dedicada a la distribución mayorista de productos farmacéuticos, biológicos, alimenticios y accesorios especializados para el sector veterinario y de la salud animal. Su operación comercial abarca una compleja red de suministro que atiende a clínicas, hospitales veterinarios y centros de distribución minoristas. Esta dinámica comercial genera un flujo constante de datos transaccionales con un alto potencial de explotación para el desarrollo de ventajas competitivas. Al enfrentarse a un mercado con demandas altamente variables, influenciadas por factores estacionales que afectan la prevalencia de ciertas condiciones de salud animal, o campañas de abastecimiento clínico, la predictibilidad de sus ingresos se convierte en un pilar operativo crítico.

Con el propósito de transformar este activo analítico en valor predictivo, se ha diseñado el Proyecto JAPI, denominado así a partir de las iniciales de los integrantes del equipo de trabajo. Este proyecto surge como un esfuerzo integrador de ciencia de datos aplicado a la infraestructura operativa de Urvet, utilizando sus registros históricos de transacciones comerciales como la fuente primaria de información.

El núcleo técnico de la investigación se centra en la incorporación, entrenamiento y evaluación comparativa de tres arquitecturas de modelado de series de tiempo de distinta naturaleza: el modelo estadístico lineal SARI-MAX, el modelo aditivo basado en curvas de crecimiento Prophet, y la red neuronal recurrente LSTM (Long Short-Term Memory).

La variable objetivo fundamental para este análisis es la proyección de las ventas netas, definida estrictamente como las ventas totales de la organización tras deducir los descuentos comerciales y las devoluciones de producto, calculadas antes de la aplicación de cargas impositivas. Si bien el horizonte de planeación y visualización estratégica se proyectará de manera mensual, el pipeline de datos está diseñado para procesar la información y generar los pronósticos con una granularidad diaria. Este nivel de detalle analítico permitirá capturar patrones de estacionalidad intra-semanal, días festivos y efectos de calendario que suelen diluirse en agregaciones macro, sentando las bases para un análisis profundo de la morfología y comportamiento de los datos que se desglosará en las secciones subsecuentes de este documento.

0.2. Objetivos

0.2.1. Objetivo General

Desarrollar e implementar un sistema predictivo robusto para la proyección de ventas netas mensuales con granularidad diaria utilizando los datos históricos de la empresa Urvet, mediante la evaluación comparativa de los modelos SARIMAX, Prophet y LSTM, con el fin de determinar la arquitectura con mayor precisión y capacidad de generalización.

0.2.2. Objetivos Específicos

- Extracción y Modelado. Diseñar e implementar un pipeline eficiente para la extracción, limpieza y agregación de los datos transaccionales de Urvet, garantizando el cálculo preciso de las ventas netas diarias antes de impuestos.
- Tratamiento Estadístico. Desarrollar mecanismos automatizados para la identificación y el tratamiento de valores atípicos *outliers* y anomalías en las series de tiempo mediante múltiples estrategias de imputación.
- Evaluación Comparativa. Evaluar el rendimiento de un modelo estadístico clásico *SARIMAX*, un enfoque de descomposición estructural *Prophet* y un modelo de aprendizaje profundo *LSTM* utilizando métricas de error estandarizadas.
- Optimización Computacional. Analizar la complejidad algorítmica y el costo computacional de cada arquitectura para asegurar la viabilidad y escalabilidad del sistema en un entorno de producción.

0.3. Metodología

El desarrollo del Proyecto JAPI se fundamentó en un enfoque metodológico de arquitectura modularizada, diseñado bajo principios de alta cohesión y bajo acoplamiento.

Esta estructura no solo garantiza la escalabilidad del sistema predictivo, sino que aísla rigurosamente cada etapa del ciclo de vida del dato, mitigando el riesgo de fuga de información y optimizando la reproducibilidad de los experimentos. El flujo de trabajo se articuló mediante un pipeline secuencial y robusto que transiciona orgánicamente desde la ingesta de las fuentes transaccionales crudas de Urvet de México hasta el despliegue del motor de evaluación comparativa de los modelos.

La arquitectura del sistema se encuentra segmentada en tres grandes módulos interdependientes:

- **Adquisición e Ingesta de Datos.** Capa encargada de la conexión, extracción y modelado de las bases de datos transaccionales. Este módulo centraliza las reglas de negocio para la consolidación de la variable objetivo, automatizando la extracción de la base de datos central de la empresa, cuidando la integridad de la misma.
- **Procesamiento y Tratamiento Estadístico.** Bloque especializado en el análisis exploratorio y la sanitización de las series temporales. A través de componentes orientados a objetos, este módulo computa dinámicamente máscaras lógicas vectorizadas para la detección de anomalías y desacopla la lógica de imputación, permitiendo al sistema despachar múltiples estrategias de corrección (como interpolaciones lineales o medias móviles vecinas) según la morfología del dato.
- **Modelado Predictivo y Evaluación.** Motor analítico donde convergen las arquitecturas SARIMAX, Prophet y LSTM. Este módulo administra de manera agnóstica el entrenamiento de los algoritmos y expone una interfaz estandarizada para someter los pronósticos a un marco riguroso de validación cruzada y métricas de error estadístico, garantizando una comparación simétrica del rendimiento predictivo.

0.3.1. Arquitectura del Repositorio y Estructura del Proyecto

Para dar soporte al enfoque modular propuesto, el sistema se organizó bajo una estructura de directorios estandarizada que separa las responsabilidades de configuración, experimentación, almacenamiento de artefactos y lógica productiva. A continuación se describe el propósito y contenido de cada componente del repositorio:

Capa de configuración y ejecución principal

- *config/*
- *core/*

El directorio de configuración centraliza los parámetros estáticos y las credenciales operativas del sistema, evitando la persistencia de variables rígidas dentro del código fuente. Este espacio gestiona las cadenas de conexión a los servidores de bases de datos y define las variables de entorno necesarias para el despliegue del proyecto. Por otro lado, la sección del núcleo operativo funge como el centro de control de la ejecución, alojando las rutinas principales que importan los módulos reutilizables y coordinan secuencialmente las fases del pipeline completo.

Capa de datos y artefactos de modelado

El almacenamiento de información y persistencia de conocimiento se divide en dos repositorios específicos:

- *data/*
Este espacio está destinado al almacenamiento de las fuentes transaccionales en formatos crudos tales como archivos de valores separados por comas o hojas de cálculo electrónicas, sirviendo además como repositorio para los conjuntos de datos que ya han sido sometidos a los procesos de limpieza y normalización.
- *models/*
Funciona como un repositorio cerrado para la preservación de los modelos finales entrenados y las definiciones estructurales de datos, resguardando archivos de extensión h5 para la red neuronal recurrente, serializaciones numéricas para el modelo estadístico lineal o formatos de intercambio de datos tipo json para configuraciones específicas de los algoritmos.

Entorno de experimentación y desarrollo

La fase de investigación y descubrimiento de insights se aísla por completo de la producción mediante un espacio exclusivo para libretas interactivas *notebooks/*. Este directorio contiene únicamente archivos de extensión ipynb o reportes exportados en lenguaje de marcado de hipertexto que documentan los análisis visuales de tendencias, correlaciones y detección de anomalías. Bajo ninguna circunstancia este módulo provee lógica al flujo productivo del sistema.

Capa de lógica reutilizable y utilidades

El motor del proyecto reside en la sección de código fuente denominada *src/*, la cual se subdivide en componentes especializados que encapsulan la lógica interna del sistema:

- *db_conn.py*
Archivo que implementa de forma exclusiva la clase encargada de gestionar el ciclo de vida de la conexión y las consultas hacia la base de datos de la organización.
- *cleaner.py*
Componente que agrupa las funciones de transformación y el despacho de algoritmos de corrección estadística una vez validada su funcionalidad operativa.

- *models.py*

Módulo orientado a objetos cuyas clases administran de manera unificada los procesos de reentrenamiento, optimización de hiperparámetros, evaluación simétrica y generación de predicciones.

0.3.2. Capa de resultados

Para mantener la lógica detrás de la estructura modularizada, se implementó un directorio exclusivo para el resguardo de datos predichos.

- *forecast/*

El tipo de datos almacenados continua con la accesibilidad a través de archivos de formato valores separados por comas, con el objetivo de que sean almacenados de forma fácil y ligera.

Finalmente, el módulo de utilidades *utils/utils.py* centraliza funciones de carácter universal que, por su naturaleza transversal, no pertenecen a una clase de negocio específica, proveyendo herramientas genéricas para la lectura de sistemas de archivos, la asignación estricta de tipos de datos o el formateo de marcas de tiempo.

0.3.3. Adquisición y Modelado de Datos

Conexión a base de datos

La estrategia de seguridad y desacoplamiento de la infraestructura analítica se fundamenta en el aislamiento de las variables críticas del sistema. Para evitar la exposición de credenciales dentro del código fuente, se implementó un esquema basado en archivos externos de entorno, los cuales resguardan los parámetros de autenticación tanto del servidor de bases de datos como del nodo intermedio de comunicación segura.

El script de configuración inicial lee dinámicamente estas variables operativas y utiliza herramientas de resolución de rutas del sistema operativo para establecer los caminos absolutos de los directorios del proyecto, garantizando la portabilidad del sistema en cualquier entorno de ejecución local. El código correspondiente a la inicialización de los entornos y asignación estática se detalla a continuación:

config/settings.py

```
1 import pathlib
2 import os
3 from dotenv import load_dotenv
4
5 load_dotenv()
6
7 DB_HOST = os.getenv('DB_HOST')
8 DB_PASSWORD = os.getenv('DB_PASSWORD')
```

```

9 DB_NAME = os.getenv('DB_NAME')
10 DB_PORT = os.getenv('DB_PORT')
11 DB_USER = os.getenv('DB_USER')
12
13 SSH_IP = os.getenv('SSH_IP')
14 SSH_PRIVATE_KEY = os.getenv('SSH_PRIVATE_KEY')
15 SSH_USERNAME = os.getenv('SSH_USERNAME')
16 SSH_PORT = os.getenv('SSH_PORT')
17
18 BASE_DIR = pathlib.Path(__file__).resolve().parent.parent
19
20 DATA_DIR = BASE_DIR / "data"
21 CONFIG_DIR = BASE_DIR / "config"
22 MODELS_DIR = BASE_DIR / "models"
23 SRC_DIR = BASE_DIR / "src"
24 NB_DIR = BASE_DIR / "notebooks"
25 FORECAST_DIR = BASE_DIR / "forecast"
26

```

Listing 1: Configuración de entornos y rutas globales en settings.py.

Extracción y consumo

Para interactuar de forma segura con los registros transaccionales de Urvet de México, se desarrolló una *clase* que gestiona la comunicación mediante un túnel cifrado de shell segura. Esta técnica redirige el tráfico de la base de datos relacional a través de un puerto local virtualizado, evadiendo la necesidad de exponer los puertos del servidor hacia redes públicas.

La clase implementada encapsula el ciclo de vida del canal de comunicación de forma automatizada. El método de conexión emplea bloques de control de excepciones y gestores de contexto para asegurar que los cursores y las conexiones con el motor de base de datos PostgreSQL se cierran correctamente tras la ejecución, mitigando la fuga de memoria o saturación de hilos en el servidor.

Asimismo, la persistencia local se optimiza volcando las consultas directamente hacia estructuras de datos tabulares, facilitando la creación de archivos planos codificados en formato universal. La abstracción completa de esta lógica de conectividad se expone en el siguiente bloque de código:

src/db_conn.py

```

1 import psycopg2
2 import pandas as pd
3 from sshtunnel import SSHTunnelForwarder
4 from config.settings import (
5     DB_HOST, DB_PASSWORD, DB_NAME, DB_PORT, DB_USER,
6     SSH_IP, SSH_PRIVATE_KEY, SSH_USERNAME, SSH_PORT
7 )
8
9 class DatabaseConnection:

```



```

10     def __init__(self, *, DB_HOST, DB_PASSWORD, DB_NAME,
11     DB_PORT, DB_USER, SSH_IP, SSH_PRIVATE_KEY, SSH_USERNAME,
12     SSH_PORT):
13         self.db_host = DB_HOST
14         self.db_password = DB_PASSWORD
15         self.db_name = DB_NAME
16         self.db_port = int(DB_PORT)
17         self.db_user = DB_USER
18         self.ssh_ip = SSH_IP
19         self.ssh_username = SSH_USERNAME
20         self.ssh_private_key = SSH_PRIVATE_KEY
21         self.ssh_port = int(SSH_PORT)
22
23     def setup_status(self):
24         print(f'DB Host: {self.db_host} -> as {type(self.
25 db_host)})')
26         print(f'DB name: {self.db_name} -> as {type(self.
27 db_name)})')
28         if not self.db_password:
29             raise ValueError('Password was not set correctly')
30         else:
31             print('Password: *')
32             print(f'DB port: {self.db_port} -> as {type(self.
33 db_port)})')
34             print(f'DB username: {self.db_user} -> as {type(self.
35 db_user)})')
36
37     def set_connection(self, *, query: str = None):
38         try:
39             with SSHTunnelForwarder(
40                 (self.ssh_ip, int(self.ssh_port)),
41                 ssh_private_key=self.ssh_private_key,
42                 ssh_username=self.ssh_username,
43                 remote_bind_address=(self.db_host, int(self.
44 db_port)),
45                 local_bind_address=('127.0.0.1', self.db_port),
46                 host_pkey_directories=[]
47             ) as server:
48                 print('Server connected')
49                 params = {
50                     'database': self.db_name,
51                     'user': self.db_user,
52                     'password': self.db_password,
53                     'host': '127.0.0.1',
54                     'port': server.local_bind_port
55                 }
56                 conn = psycopg2.connect(params)
57                 curs = conn.cursor()
58
59                 if query is None:
60                     print("database connected")
61                     curs.close()
62                     conn.close()
63                     return True

```

```

57         else:
58             print(f'Query: {query}')
59             curs.execute(query)
60             headers = [desc[0] for desc in curs.
description]
61             res = curs.fetchall()
62             curs.close()
63             conn.close()
64             return res, headers
65         except Exception as e:
66             print(f'Connection error. {e}')
67
68     def query_to_csv(self, *, query: str = None,
output_file_name: str = 'output.csv'):
69         try:
70             if not query:
71                 print("There is no query provided")
72                 return False
73             data, headers = self.set_connection(query=query)
74             df = pd.DataFrame(data, columns=headers)
75             print("\nPreview\n")
76             print(df.head())
77             df.to_csv(output_file_name, index=False, encoding='
utf-8')
78             print(f"\nDF successfully created and saved as '{
output_file_name}'")
79             return df
80         except Exception as e:
81             print(f"Error while exporting to CSV: {e}")
82             return False
83

```

Listing 2: Clase de gestión de conexión segura y persistencia en db_conn.py.

Modelado de datos

El proceso de modelado requiere una fase previa de estructuración y homogeneización de los tipos de datos transaccionales, garantizando que las series de tiempo posean la alineación matemática adecuada antes de ser inyectadas en las fases de entrenamiento analítico.

Primer acercamiento. El flujo de trabajo se inicializa en el componente ejecutor principal del sistema *main.py*. En esta aproximación temprana, el pipeline realiza la instanciación del objeto de conexión, ejecuta una consulta masiva para recuperar la totalidad del histórico transaccional de ventas y genera el archivo plano intermedio en la ruta de almacenamiento de datos previamente resuelta.

Posteriormente, se lleva a cabo un proceso de alineación en los metadatos de la estructura relacional, forzando la conversión del identificador de

ruta hacia un formato entero extendido con soporte para valores nulos y transformándolo finalmente en una cadena de texto homogénea.

Esta transformación previene inconsistencias de indexación durante los cruces matriciales subsecuentes. El flujo operativo inicial se detalla a continuación:

core/main.py

```
1 from src.db_conn import DatabaseConnection
2 from src.models import SarimaxModel
3 from src.cleaner import Cleaner
4 from config.settings import (
5     DB_HOST, DB_PASSWORD, DB_NAME, DB_PORT, DB_USER,
6     SSH_IP, SSH_PRIVATE_KEY, SSH_USERNAME, SSH_PORT,
7     DATA_DIR, FORECAST_DIR, MODELS_DIR
8 )
9 import pandas as pd
10 import json
11
12 def main():
13     db_conn = DatabaseConnection(
14         DB_HOST=DB_HOST, DB_NAME=DB_NAME, DB_PASSWORD=
15         DB_PASSWORD,
16         DB_PORT=DB_PORT, DB_USER=DB_USER, SSH_PRIVATE_KEY=
17         SSH_PRIVATE_KEY,
18         SSH_IP=SSH_IP, SSH_USERNAME=SSH_USERNAME, SSH_PORT=
19         SSH_PORT
20     )
21
22     sales_query = """
23     SELECT * FROM sale_transactions
24     """
25     output_path = f'{DATA_DIR}/sales.csv'
26
27     sales = db_conn.query_to_csv(query=sales_query,
28     output_file_name=output_path)
29     sales['route_id'] = sales['route_id'].astype('Int64').
30     astype(str)
```

Listing 3: Orquestación inicial e ingesta transaccional en main.py.

0.3.4. Análisis Exploratorio de Datos

El análisis exploratorio de datos constituye la fase analítica preliminar orientada a caracterizar la morfología de la información extraída, identificar anomalías estructurales y validar las propiedades estadísticas de las series de tiempo antes de su procesamiento predictivo.

Aislamiento del Entorno de Ejecución y Extracción Core

Para garantizar la reproducibilidad de las pruebas estadísticas y aislar el entorno de desarrollo interactivo del pipeline de producción, se implementó una rutina de resolución dinámica de rutas del sistema que inyecta el directorio raíz en el camino de búsqueda de los módulos del sistema. Esto permite reutilizar los componentes de conectividad previamente desarrollados.

El bloque de inicialización de librerías científicas y configuración de formatos numéricos se presenta a continuación:

notebooks/eda.ipynb

```
1 from pathlib import Path
2 import sys
3
4 ROOT_DIR = Path.cwd().parent
5
6 if str(ROOT_DIR) not in sys.path:
7     sys.path.insert(0, str(ROOT_DIR))
8
9 from src.db_conn import DatabaseConnection
10 from config.settings import (
11     DB_HOST, DB_PASSWORD, DB_NAME, DB_PORT, DB_USER,
12     SSH_IP, SSH_PRIVATE_KEY, SSH_USERNAME, SSH_PORT, DATA_DIR
13 )
14
15 import pandas as pd
16 pd.options.display.float_format = '{:,.2f}'.format
17
18 import numpy as np
19 import matplotlib.pyplot as plt
20 import seaborn as sns
21
22 from statsmodels.tsa.seasonal import seasonal_decompose
23 from statsmodels.tsa.stattools import adfuller
24
```

Listing 4: Configuración del entorno interactivo e importación de dependencias.

Tras mapear el catálogo global de la base de datos operativa de Urvet de México, se identificaron cuarenta y nueve entidades relacionales activas. Con el objetivo de optimizar los recursos de cómputo y focalizar el esfuerzo analítico en el comportamiento transaccional del mercado, el alcance de la investigación se delimitó estrictamente a la extracción de dos entidades núcleo: la tabla maestro de clientes y el registro histórico de transacciones de venta.

La persistencia de estas entidades en archivos planos asegura que cada corrida del pipeline cuente con una evidencia inmutable del último conjunto de datos utilizado, facilitando las auditorías del modelo. El proceso de extracción interactivo se detalla en el siguiente segmento de código:

notebooks/eda.ipynb

```

1 new_conn = DatabaseConnection(
2     DB_HOST=DB_HOST, DB_NAME=DB_NAME, DB_PASSWORD=DB_PASSWORD,
3     DB_PORT=DB_PORT, DB_USER=DB_USER, SSH_PRIVATE_KEY=
4     SSH_PRIVATE_KEY,
5     SSH_IP=SSH_IP, SSH_USERNAME=SSH_USERNAME, SSH_PORT=SSH_PORT
6 )
7 sale_transactions_query = """
8 SELECT * FROM sale_transactions
9 """
10
11 customers_query = """
12 SELECT * FROM customers
13 """
14
15 new_conn.setup_status()
16 new_conn.query_to_csv(query=sale_transactions_query,
17     output_file_name=DATA_DIR / 'sales.csv')
18 new_conn.query_to_csv(query=customers_query, output_file_name=
19     DATA_DIR / 'customers.csv')

```

Listing 5: Consumo y persistencia local de las entidades relacionales core.

Carga de Datos e Inspección de Estructuras

Una vez realizado el volcado de la base de datos, las fuentes se cargan en estructuras tabulares en memoria para validar su correcta disposición columnar. La tabla maestro de clientes provee los atributos críticos para la futura segmentación comercial, incluyendo identificadores, fechas de alta operativas y límites de crédito. Por su parte, la tabla de transacciones de venta constituye el núcleo temporal del proyecto, registrando las marcas de tiempo, los costos totales y los precios netos requeridos por los modelos de aprendizaje profundo y econométricos.

```

1 customers = pd.read_csv(DATA_DIR / 'customers.csv')
2 sales = pd.read_csv(DATA_DIR / 'sales.csv')
3
4 display(customers.head())
5 display(sales.head())
6

```

Listing 6: Lectura de los conjuntos de datos hacia estructuras tabulares.

Evaluación de Completitud e Integridad del Corpus

La calidad del modelado de series de tiempo depende críticamente de la continuidad de los registros. Por ello, se ejecutó una rutina de auditoría de valores faltantes sobre cada matriz con la finalidad de trazar un mapa de nulidades. El diagnóstico del estado de completitud se procesó mediante el siguiente script:

```

1 print('Conteo de nulos de sales')
2 print(sales.isna().sum())
3
4 print('Conteo de nulos de customers\n')
5 print(customers.isna().sum())
6

```

Listing 7: Auditoría de valores nulos en los conjuntos de datos.

Los resultados demuestran que la estructura de clientes presenta una integridad absoluta con cero registros nulos en todas sus dimensiones. En contraparte, la matriz transaccional exhibe seiscientos ochenta y nueve ausencias en el identificador de producto y tres mil setenta y ocho nulidades en el identificador de ruta comercial.

Desde una perspectiva de negocio, estas anomalías indican transacciones globales no vinculadas a canales de distribución específicos o registros huérfanos que demandarán una estrategia de filtrado o imputación guiada en las etapas subsecuentes, previniendo la distorsión de las tendencias por falta de consistencia geográfica.

0.3.5. Limpieza y Normalización

La fase de preprocesamiento técnico tiene como objetivo estandarizar las estructuras de los conjuntos de datos, asegurando la consistencia operativa antes de la agregación temporal. Este proceso es un requisito crítico debido a que el sistema operará bajo diferentes niveles de granularidad para satisfacer las demandas de proyecciones macro es decir, análisis globales diarios o segmentados por centro de distribución y proyecciones micro, las cuales requieren un nivel de detalle diario por ruta comercial o consolidaciones mensuales por cliente.

Dado que el análisis se ejecuta estrictamente sobre las ventas netas, la presencia de notas de crédito y registros atípicos requiere un proceso riguroso de tipado y sanitización para asegurar que las transformaciones posteriores permitan a los modelos clásicos y de aprendizaje profundo discriminar correctamente las señales de la demanda.

Estandarización de Formatos y Tipos de Datos

El primer paso operativo consistió en homologar los tipos de datos en la matriz transaccional, la cual cuenta con un histórico de seiscientos noventa y siete mil setecientos cincuenta registros. Se transformó la variable temporal mediante un proceso de conversión explícita hacia estructuras cronológicas de alta precisión, anulando cualquier registro que presente inconsistencias de origen.

De forma paralela, las columnas financieras y de conteo de existencias se castearon hacia valores numéricos de punto flotante de sesenta y cuatro bits,

mientras que los identificadores categóricos se unificaron en cadenas de texto homogéneas, implementando un tratamiento especial para el identificador de rutas comerciales mediante un tipo entero extendido. El snippet para este proceso se detalla a continuación:

notebooks/eda.ipynb

```
1 sales['sale_date'] = pd.to_datetime(sales['sale_date'], errors=
    'coerce')
2
3 num_cols = [
4     'total_cost', 'net_price', 'gross_price', 'profit', '
    quantity'
5 ]
6
7 cat_cols = [
8     'customer_id', 'product_id', 'product_class_id', '
    warehouse_id', 'route_id'
9 ]
10
11 for col in num_cols:
12     sales[col] = pd.to_numeric(sales[col], errors='coerce').
    astype(float)
13
14 for col in cat_cols:
15     if col == 'route_id':
16         sales[col] = sales[col].astype('Int64').astype(str)
17     else:
18         sales[col] = sales[col].astype(str)
19
```

Listing 8: Homologación de tipos de datos macro y micro en la matriz de ventas.

Imputación de Valores Nulos

Para evitar la pérdida de registros históricos y mantener la integridad total de las observaciones transaccionales, se rechazó la estrategia de eliminación física de filas. En su lugar, se optó por un enfoque de imputación por categorías genéricas explícitas para las variables de ruta y producto.

Este procedimiento sustituye las ausencias lógicas detectadas previamente por etiquetas de texto estructuradas, lo cual permite conservar la trazabilidad de la facturación global sin alterar la consistencia de las agrupaciones geográficas, logrando reducir el conteo de valores nulos a cero en todo el corpus operativo. La implementación de este proceso se detalla en el siguiente fragmento de código:

notebooks/eda.ipynb

```
1 sales['route_id'] = sales['route_id'].fillna('ruta no
    especificada')
2 sales['product_id'] = sales['product_id'].fillna('producto no
    asignado')
```

```

3
4 print('Conteo de nulos de sales')
5 print(sales.isna().sum())
6 sales.info()
7

```

Listing 9: Algoritmo de imputación categórica para variables de control.

Reconocimiento de Medidas de Tendencia Central y Análisis de Anomalías

Una vez removido el identificador subyacente y consolidada la estructura limpia del dataframe, se calcularon los estimadores estadísticos fundamentales sobre las variables numéricas de la matriz transaccional para auditar la distribución real de las operaciones financieras.

Los resultados numéricos demuestran una asimetría severa hacia la derecha en la distribución de los ingresos de Urvet de México. El precio neto de las transacciones presenta una media de mil doscientos noventa y dos unidades monetarias con dieciocho centavos, mientras que el valor de la mediana se posiciona marcadamente por debajo, situándose en seiscientas veinticuatro unidades con veintinueve centavos. Esta brecha, sumada a una desviación estándar elevada de doce mil treinta y cuatro unidades con ochenta y cuatro centavos, confirma la dispersión natural del modelo de distribución mayorista, donde el comportamiento habitual está compuesto por órdenes veterinarias base de bajo valor, interrumpidas esporádicamente por picos de facturación masivos que alcanzan un valor máximo absoluto de dos millones quinientas cuarenta mil seiscientas noventa y siete unidades con treinta y seis centavos.

El hallazgo más crítico de esta inspección estadística reside en los valores mínimos registrados en las dimensiones financieras. El precio neto y la utilidad mínima exhiben valores negativos extremos de menos cuatro millones doscientas treinta y tres mil seiscientas treinta y cuatro unidades con cincuenta y ocho centavos, un patrón que se correlaciona directamente con un volumen mínimo negativo de menos mil ochocientas cuarenta y cinco unidades de producto.

En la lógica de negocio de la organización, estos registros negativos representan la aplicación de notas de crédito comerciales, correcciones contables o devoluciones masivas de inventario. Debido a que las arquitecturas predictivas SARIMAX, Prophet y LSTM asumen distribuciones continuas y valores no invertidos para modelar la demanda regular, la presencia de estos valores negativos distorsiona el aprendizaje de las curvas de tendencia, marcando la necesidad imperativa de diseñar transformaciones y filtros específicos en la siguiente etapa del pipeline.

Visualización de Distribuciones

El análisis visual de las desviaciones estándar y los rangos de dispersión se consolidó mediante la generación de diagramas de caja y bigotes. Estos componentes gráficos permiten identificar de manera geométrica la concentración de los datos transaccionales, la localización de los rangos intermedios y la extensión de sus colas extremas.

Exploración General del Corpus Transaccional. Como primera aproximación, se sometió la variable de precio neto a una rutina de graficación para mapear la totalidad de los registros de venta, exponiendo la dispersión absoluta de la operación comercial de Urvet de México sin aplicar filtros geográficos o de canal. El snippet desarrollado se detalla a continuación:

notebooks/eda.ipynb

```
1 sns.set_theme(style="white")
2 plt.figure(figsize=(10, 4), dpi=100)
3
4 sns.boxplot(
5     x=sales_prep['net_price'],
6     color='#4361ee',
7     width=0.4,
8     linewidth=1.8,
9     fliersize=4,
10    flierprops={
11        'markerfacecolor': '#e63946',
12        'markeredgecolor': 'none',
13        'alpha': 0.5
14    }
15 )
16
17 plt.title('Distribucion general de venta neta', fontsize=14,
18          pad=15, fontweight='bold', color='#212529')
19 plt.xlabel('Precio Neto ($)', fontsize=11, labelpad=10, color='
20          #495057')
21
22 sns.despine(left=True)
23 plt.grid(axis='x', linestyle='--', alpha=0.5)
24 plt.tight_layout()
25 plt.show()
```

Listing 10: Construcción del diagrama de caja general para el precio neto.




Figura 1: Distribución geométrica general de la variable precio neto transaccional.

Aislamiento de la Operación Tradicional. Al evaluar el primer diagrama, se detectó una distorsión masiva inducida por operaciones en los extremos de la distribución. Con el objetivo de aislar el comportamiento de los canales de venta físicos, se procedió a remover del conjunto de datos la ruta noventa, la cual corresponde exclusivamente al canal de comercio electrónico, debido a que su dinámica transaccional difiere del modelo de distribución mayorista tradicional. El proceso de filtrado y su correspondiente representación gráfica se detallan a continuación:

notebooks/eda.ipynb

```

1  sales_wn_90 = sales_prep[sales_prep['route_id'] != '90']
2
3  sns.set_theme(style="white")
4  plt.figure(figsize=(10, 4), dpi=100)
5
6  sns.boxplot(
7      x=sales_wn_90['net_price'],
8      color='#4361ee',
9      width=0.4,
10     linewidth=1.8,
11     fliersize=4,
12     flierprops={
13         'markerfacecolor': '#e63946',
14         'markeredgecolor': 'none',
15         'alpha': 0.5
16     }
17 )
18
19 plt.title('Distribucion general de venta neta sin ruta 90
ecommerce', fontsize=14, pad=15, fontweight='bold', color=
'#212529')
20 plt.xlabel('Precio Neto ($)', fontsize=11, labelpad=10,
color='#495057')
21
22 sns.despine(left=True)
23 plt.grid(axis='x', linestyle='--', alpha=0.5)

```

```

24 plt.tight_layout()
25 plt.show()
26
27

```

Listing 11: Filtrado del canal de comercio electrónico y generación de la distribución corregida.




Figura 2: Distribución del precio neto tras la exclusión de las transacciones de comercio electrónico.

Segmentación por Centros de Distribución. Para comprender la procedencia de las dispersiones extremas, se segmentó la matriz filtrada por cada centro de distribución activo en la organización. Este nivel de granularidad expone el comportamiento logístico individual y las diferencias operativas entre las regiones geográficas, implementando la siguiente rutina de visualización:

notebooks/eda.ipynb

```

1  sns.set_theme(style="white")
2  plt.figure(figsize=(10, 6), dpi=100)
3
4  sns.boxplot(
5      data=sales_wn_90,
6      x='net_price',
7      y='warehouse_id',
8      hue='warehouse_id',
9      palette='Set2',
10     width=0.5,
11     linewidth=1.8,
12     fliersize=4,
13     flierprops={
14         'markerfacecolor': '#e63946',
15         'markeredgecolor': 'none',
16         'alpha': 0.4
17     }
18 )
19

```

```

20 plt.title('Comparativa de Venta Neta por CEDIS (Sin Ruta 90
    E-commerce)', fontsize=14, pad=15, fontweight='bold',
    color='#212529')
21 plt.xlabel('Precio Neto ($)', fontsize=11, labelpad=10,
    color='#495057')
22 plt.ylabel('Centro de Distribuci\on (CEDIS)', fontsize=11,
    labelpad=10, color='#495057')
23
24 sns.despine(left=True, trim=True)
25 plt.grid(axis='x', linestyle='--', alpha=0.5)
26
27 plt.tight_layout()
28 plt.show()
29

```

Listing 12: Comparativa de distribuciones financieras segmentada por almacén de origen.




Figura 3: Análisis comparativo de dispersión y valores atípicos entre los diferentes centros de distribución.

Criterio Estadístico contra la Naturaleza del Negocio. Matemáticamente, la librería gráfica utilizada no evalúa los datos con base en el promedio, sino que emplea el rango intercuartílico para delimitar los umbrales de normalidad estadística. La caja central abarca el cincuenta por ciento de las transacciones comerciales, comprendido desde el primer cuartil hasta el tercer cuartil. Los límites máximo y mínimo permisibles para la declaración de valores ordinarios se encuentran modelados por las siguientes expresiones:

$$\text{Límite Superior} = Q_3 + 1,5 \times \text{IQR}$$

$$\text{Límite Inferior} = Q_1 - 1,5 \times \text{IQR}$$

Cualquier registro transaccional que exceda estos umbrales calculados es representado en los diagramas como un punto rojo aislado identificado analíticamente como un outlier o valor atípico.

En el contexto operativo de Urvet de México, la inmensa mayoría de los comprobantes generados en las rutas comerciales corresponden a compras cotidianas de bajo volumen, lo que provoca que la caja se comprima severamente cerca del origen numérico cero. Cuando ocurren eventos comerciales de alto impacto, la escala matemática se rompe, dividiéndose en dos fenómenos corporativos específicos:

- Picos positivos. Pedidos especiales ejecutados por distribuidores pesados que realizan compras de gran volumen por montos de cientos de miles o millones de pesos de forma esporádica.
- Picos negativos. Generación de notas de crédito comerciales masivas y devoluciones de mercancía de gran escala que impactan directamente el indicador de precio neto de venta.

Evaluación Operativa por Centros de Distribución. El análisis de los diagramas segmentados permite categorizar el comportamiento del mercado en tres perfiles de operación claros:

- Centro de distribución sin clasificar.
Identificado con la etiqueta snc, presenta una dispersión atípica masiva en el espectro negativo, registrando movimientos que alcanzan valores de menos uno punto cinco millones de pesos. Este comportamiento dicta la existencia de devoluciones consolidadas o notas de crédito de gran escala aplicadas a cuentas corporativas. Sin embargo, este comportamiento es completamente normal considerando que este centro se emplea para registrar ajustes contables de rutas o clientes que ya no existen. Por lo tanto, no es viable eliminar estos registros, debido a que se siguen utilizando día con día y forman parte del comportamiento logístico e histórico de la organización.
- Centros de distribución de Guadalajara y Ciudad de México.
Etiquetados como gdl y cdmx respectivamente, muestran las colas de puntos atípicos más largas en el espectro positivo. Estas regiones geográficas concentran a los clientes mayoristas con mayor poder de compra, rompiendo constantemente los techos de venta promedio de la ruta tradicional.
- Centro de distribución de comercio electrónico.
Identificado como ecm, muestra una distribución compacta y libre de valores atípicos significativos, lo cual se logró gracias a la remoción previa de la ruta noventa del canal digital.

Agrupaciones y Transformaciones de Frecuencia

La naturaleza transaccional de los registros crudos demanda una transformación estructural para posibilitar el modelado de series de tiempo. Para transicionar de un enfoque transaccional a uno temporal continuo, se aisló la columna de la fecha de venta, estableciéndola como el índice de la matriz de datos. Posteriormente, se ordenaron los registros de forma cronológica estricta para garantizar que las rutinas de remuestreo pudieran rellenar los vacíos temporales con ventas equivalentes a cero.

Una vez indexado el conjunto, se aplicó una agrupación con frecuencia diaria sobre la variable de precio neto. Este procedimiento matemático consolida todos los ingresos registrados en una misma jornada, estructurando la serie continua de ochocientas sesenta y cinco observaciones que requieren los algoritmos predictivos.

```
1 sales_wn_90['sale_date'] = pd.to_datetime(sales_wn_90['  
   sale_date'], errors='coerce')  
2 sales_date_index = sales_wn_90.set_index('sale_date')  
3 sales_date_index = sales_date_index.sort_index()  
4  
5 sales_agg_daily = sales_date_index['net_price'].  
   resample('D').sum()  
6
```

Listing 13: Conversión de índice temporal y agrupación de ventas con frecuencia diaria.

Hallazgo de Anomalías Negativas Críticas. A nivel transaccional, se habían detectado múltiples desviaciones severas. Al consolidar la serie de tiempo por día, el impacto de ciertas anomalías menores disminuyó gracias a la compensación natural con los ingresos positivos generados por las rutas. Sin embargo, la inspección gráfica de la evolución diaria de ingresos reveló un evento de extrema criticidad.

Durante el mes de julio del año dos mil veinticuatro, la serie histórica registró una caída vertical atípica que arrastró el neto consolidado de toda la organización hasta menos dos punto cinco millones de pesos en una sola jornada. Al tratarse de un conjunto de datos agrupado por día, este hallazgo confirma que no se trata de un error de captura aislado, sino de un impacto financiero masivo, como la ejecución de una devolución corporativa o la aplicación de notas de crédito de gran escala, que distorsiona por completo la varianza normal del ecosistema comercial.




Figura 4: Evolución histórica diaria de la venta neta exponiendo la anomalía financiera.

Identificación Visual de Estacionalidad Semanal. De forma paralela a la detección de anomalías, la visualización de la evolución temporal expuso un comportamiento cíclico altamente repetitivo con una morfología de dientes de sierra. Se observan caídas sistemáticas que descienden de forma casi idéntica cada siete días, lapso que coincide de manera natural con los días de descanso o nula distribución en campo, seguidas inmediatamente por picos de surtido acelerado a mitad de semana.

Aunque este comportamiento cíclico será evaluado matemáticamente más adelante mediante funciones de autocorrelación, esta hipótesis visual robusta proporciona una guía estructural directa para la futura calibración de los hiperparámetros. En el caso del modelo SARIMAX, este comportamiento dicta la necesidad de configurar el parámetro de estacionalidad en siete periodos.




Figura 5: Distribución agrupada diaria que expone los picos atípicos en ambos polos.

Estrategias Opuestas para el Tratamiento de Valores Atípicos. El análisis del diagrama de caja agrupado delimitó dos clases de puntos ex-

tremos que, dada su naturaleza de origen, requieren protocolos de limpieza diametralmente opuestos.

Hacia el espectro positivo, el gráfico detectó siete registros que superaron masivamente el límite superior de normalidad, rompiendo techos de hasta cuatro punto seis millones de pesos diarios. A diferencia del evento de caída, estos picos revelan un patrón comercial sistemático e impulsado por el mercado: el efecto del cierre de mes y fin de trimestre. Las fechas de estos máximos históricos coinciden con las jornadas donde la fuerza de ventas de Urvet de México concentra operaciones de gran volumen para alcanzar cuotas de distribución.

Bajo este contexto, la directriz metodológica prohíbe estrictamente eliminar o suavizar los picos de facturación positiva, ya que representan la verdadera demanda límite de la cadena de suministro. Para que las arquitecturas predictivas capturen estos saltos dinámicos, el pipeline de datos implementará ingeniería de características mediante variables exógenas de intervención temporal, permitiendo al algoritmo anticipar estos comportamientos.

En contraparte, el polo negativo exige una corrección intrusiva. Preservar la caída de julio del dos mil veinticuatro sesgaría las predicciones futuras hacia abajo y deformaría los pesos de la red neuronal. Simultáneamente, eliminar la fila del registro destruiría la continuidad del calendario, provocando un error en cascada por la pérdida de la frecuencia temporal. Para solucionar esta inconsistencia matemática, se diseñó un protocolo de imputación por interpolación lineal.

```
1 sales_agg_daily_final = sales_agg_daily.copy()
2
3 outs_days = sales_agg_daily_final[sales_agg_daily_final
4 < 0].index
5 print(f"Días anomalos detectados por regla de negocio:
6 {len(outs_days)}")
7
8 sales_agg_daily_final[sales_agg_daily_final < 0] = np.
nan
sales_agg_daily_final = sales_agg_daily_final.
interpolate(method='linear')
```

Listing 14: Protocolo automatizado de interpolación lineal para limpieza de anomalías negativas.

Consolidación de la Serie Limpia El barrido automatizado identificó dieciocho días con balances netos negativos, una cifra que representa menos del dos por ciento del volumen de datos analizado. Ante esta proporción marginal, el algoritmo procedió a sustituir los montos de dichas jornadas por valores nulos, ejecutando inmediatamente una interpolación lineal. Este método matemático calcula la pendiente entre el día previo y el posterior a

la anomalía, uniendo ambos puntos mediante una recta que suaviza el cráter de forma local. Este mecanismo restaura la sanidad financiera de la serie de tiempo continua, conservando intacta la capacidad de la red para procesar la volatilidad operativa de los datos.




Figura 6: Serie de tiempo continua y estabilizada tras el proceso de interpolación matemática.




Figura 7: Distribución final preservando exclusivamente los picos positivos operativos.

Pruebas de Hipótesis y Diagnóstico de Componentes

Antes de proceder a la fase de entrenamiento predictivo, resulta mandatorio desglosar los componentes estructurales subyacentes de la serie temporal mediante el planteamiento y ejecución de pruebas de hipótesis. Este diagnóstico permite validar si los datos cumplen con los supuestos matemáticos requeridos por los algoritmos estadísticos y define la necesidad de implementar transformaciones previas, tales como diferenciaciones o inclusión de variables exógenas.

Estacionalidad y Descomposición Estructural. Con el fin de confirmar numéricamente los patrones cíclicos observados durante la fase explo-

ratoria, se aplicó un filtro de descomposición aditiva sobre la serie histórica diaria, aislando la tendencia general, la variabilidad estacional y el componente residual.

Considerando la hipótesis planteada en la visualización previa, se definió un periodo paramétrico de siete periodos. La instrumentación técnica de este proceso y su consecuente mapeo gráfico se exponen a continuación:

```

1  decompose = seasonal_decompose(sales_agg_daily_final, model='
    additive', period=7)
2
3  sns.set_theme(style="white")
4
5  observed = decompose.observed
6  trend = decompose.trend
7  seasonal = decompose.seasonal
8  resid = decompose.resid
9
10 fig, axes = plt.subplots(4, 1, figsize=(12, 10), sharex=True,
    dpi=100)
11
12 axes[0].plot(observed.index, observed.values, color='#4361ee',
    linewidth=1.5, alpha=0.8)
13 axes[0].set_ylabel('Venta Real ($) ', fontsize=10, fontweight='
    bold', color='#495057')
14 axes[0].set_title('Descomposicion Analitica de la Serie
    Temporal (Ciclo Semanal, s=7)',
15                   fontsize=14, pad=15, fontweight='bold', color='
    #212529')
16
17 axes[1].plot(trend.index, trend.values, color='#3f37c9',
    linewidth=2.2)
18 axes[1].set_ylabel('Tendencia ($) ', fontsize=10, fontweight='
    bold', color='#495057')
19
20 axes[2].plot(seasonal.index, seasonal.values, color='#4cc9f0',
    linewidth=1.2)
21 axes[2].set_ylabel('Estacionalidad ($) ', fontsize=10,
    fontweight='bold', color='#495057')
22
23 axes[3].scatter(resid.index, resid.values, color='#e63946',
    alpha=0.4, s=20)
24 axes[3].axhline(0, color='#212529', linestyle='--', linewidth=1,
    alpha=0.5)
25 axes[3].set_ylabel('Residuo ($) ', fontsize=10, fontweight='bold
    ', color='#495057')
26 axes[3].set_xlabel('Fecha de Venta', fontsize=11, labelpad=10,
    color='#495057')
27
28 for ax in axes:
29     ax.grid(axis='both', linestyle='--', alpha=0.3)
30     sns.despine(ax=ax, left=False, bottom=False)
31     ax.tick_params(axis='both', labelsize=10, colors='#495057')
32

```

```

33 plt.tight_layout(h_pad=1.8)
34 plt.show()
35

```

Listing 15: Descomposición aditiva y aislamiento del componente estacional.




Figura 8: Aislamiento de la tendencia a largo plazo y comprobación visual del ciclo estacional de siete días.

Los hallazgos derivados de los paneles de descomposición proporcionan el sustento algorítmico para la configuración del pipeline:

- Consolidación de la estacionalidad.
Existe evidencia gráfica contundente de un patrón estacional regular a lo largo de todo el histórico. El componente identifica un valle recurrente de menos setecientos cincuenta mil pesos respecto a la línea base durante los días de nula actividad logística, el cual es compensado de forma simétrica por crestas operativas. Este hallazgo rechaza la hipótesis nula de ausencia de temporalidad y bloquea de forma definitiva el hiperparámetro estacional de los modelos lineales en una frecuencia equivalente a un ciclo semanal continuo.
- Análisis del residuo comercial.
El residuo representa la varianza que ni la tendencia de largo plazo

ni el ciclo semanal lograron absorber. En condiciones ideales, este panel debería exhibir ruido blanco homogéneo. No obstante, se aprecian ráfagas de picos positivos que superan el millón de pesos de forma intermitente, coincidiendo exactamente con los días de cierre de mes. Esta evidencia justifica de manera obligatoria el diseño de una matriz exógena para inyectarla en la arquitectura SARIMAX, absorbiendo así el impacto de estos eventos comerciales sin corromper la memoria residual.

Prueba de Estacionariedad por Raíz Unitaria Para garantizar que los estimadores predictivos no converjan hacia valores infinitos durante el cálculo de matrices de pesos, resulta fundamental validar si las propiedades estadísticas de la serie, específicamente su media y su varianza, permanecen constantes a lo largo del tiempo.

Con este fin, se ejecutó el test de Dickey-Fuller Aumentada bajo el siguiente marco de comprobación estadística:

- Hipótesis Nula.
La serie de tiempo posee una raíz unitaria, implicando no estacionariedad, dependencia temporal fuerte y una media fluctuante.
- Hipótesis Alternativa.
La serie carece de raíz unitaria, logrando estacionariedad y distribuyendo sus observaciones en torno a una media finita.

```
1 result = adfuller(sales_agg_daily_final)
2
3 print(f"ADF: {result[0]:.4f}")
4 print(f"p-value: {result[1]:.4f}")
5 print("Valores criticos:")
6 for k, v in result[4].items():
7     print(f"{k}: {v:.4f}")
8
9 if result[1] <= 0.05:
10     print("\n>> p-value <= 0.05, se rechaza H0, la serie es
    estacionaria")
11 else:
12     print("\n>> p-value > 0.05: no se rechaza H0. La serie
    no es estacionaria")
13
```

Listing 16: Ejecución del test estadístico de Dickey-Fuller Aumentada.

La ejecución arrojó un valor p de cero punto cero diecisiete, logrando superar el umbral estricto de significancia del cinco por ciento. Numéricamente, el estadístico de prueba dictaminó el rechazo de la hipótesis nula, catalogando la serie de ventas netas como estacionaria.

A pesar del veredicto matemático emitido por la prueba, el enfoque metodológico de un proyecto de ciencia de datos requiere un análisis holístico que trascienda la evaluación unidimensional.

Al contrastar el estadístico de Dickey-Fuller contra el panel visual de la tendencia estructural aislado previamente en la Figura 8, se identifica una discrepancia empírica severa. La línea de tendencia subyacente exhibe una pendiente ascendente prolongada a partir del segundo cuatrimestre del último año, indicando claramente que el crecimiento orgánico del negocio ha comenzado a alterar la media móvil histórica de la organización.

Por consiguiente, y como medida preventiva para maximizar la capacidad de ajuste algorítmico, las arquitecturas predictivas evaluarán configuraciones dinámicas que incluyan grados de diferenciación integral, el parámetro diferencial en los modelos ARIMA clásicos, con el objetivo de aplanar artificialmente cualquier rastro de inercia ascendente antes del entrenamiento computacional, blindando así los pronósticos contra un eventual sesgo exponencial.

0.3.6. Ingeniería de Características

El desarrollo y enriquecimiento de las variables de estudio se fundamenta en el conocimiento empírico derivado de la operación comercial logística de la organización. A partir de la experiencia directa del negocio, se identificaron factores temporales externos con alta probabilidad de influir en el volumen de demanda, los cuales resultan críticos para maximizar la capacidad de generalización y la precisión de las predicciones en etapas posteriores.

Entre las variables de mayor impacto aisladas para este estudio destacan tres eventos de calendario: en primer lugar, la validación de días feriados inactivos dictaminados por la legislación laboral; en segundo lugar, la identificación estricta de las jornadas de cierre de mes contable; y finalmente, el marcado de la zona de cierre operativo, la cual comprende los últimos tres días de cada ciclo mensual, periodo específico donde la fuerza de ventas concentra y acelera las transacciones de alto volumen.

Para instrumentar este conocimiento operativo en el entorno algorítmico, se procedió a transformar el índice temporal crudo en una matriz de características exógenas. Este arreglo matricial contiene indicadores lógicos binarios ceros y unos que actúan como banderas de intervención temporal. Posteriormente, esta matriz se concatenó de forma lateral con la serie de tiempo univariada, generando un conjunto de datos maestro preparado para ser consumido por las arquitecturas de aprendizaje profundo y estadístico. La implementación analítica se expone a continuación:

```
1 exo_matrix = exo_matrix_mapping(sales_agg_daily_final)
2 master = pd.concat([sales_agg_daily_final, exo_matrix], axis=1)
```

Listing 17: Creación y concatenación de la matriz de características exógenas.

La estructura resultante acopla la variable continua de precio neto con las tres dimensiones exógenas calculadas. Para ilustrar la consolidación de este conjunto maestro, se presenta el esquema de los registros finales donde se aprecian las activaciones de las banderas lógicas correspondientes a la zona de cierre y al fin de mes durante los días previos a la clausura operativa de mayo del dos mil veintiséis:

Tabla 1: Estructura final de la matriz maestra con variables de intervención temporal.

<i>sale_date</i>	<i>net_price</i>	<i>non_work_day</i>	<i>is_month_end</i>	<i>close_month_zone</i>
2026-05-11	1,790,415.58	0	0	0
2026-05-12	2,139,962.69	0	0	0
2026-05-13	1,245,428.49	0	0	1
2026-05-14	1,656,746.25	0	0	1
2026-05-15	646,434.79	0	1	0

Como paso conclusivo del análisis exploratorio, la ingeniería de características y la sanitización general de información, la matriz maestra fue exportada hacia un archivo de almacenamiento plano de valores separados por comas. Este artefacto fungirá a partir de este momento como la fuente unificada e inmutable de la verdad estadística para los experimentos de entrenamiento computacional de los modelos SARIMAX, Prophet y LSTM.

```
1 master.to_csv(f"{DATA_DIR}/master.csv")
```

Listing 18: Persistencia local del conjunto maestro consolidado.

0.3.7. Machine Learning, Deep Learning y Modelos Estadísticos Clásicos

SARIMAX

Desglose Matemático. El modelo SARIMAX (Seasonal AutoRegressive Integrated Moving Average with exogenous regressors) se estructura mediante parámetros que controlan tanto la estacionalidad como la tendencia histórica. En su notación algorítmica, los parámetros p , d , y q representan el orden autorregresivo, el grado de diferenciación y el orden de la media móvil respectivamente.

De manera homóloga, P , D , y Q rigen estos mismos componentes pero aplicados estrictamente a la parte estacional, acompañados por el factor m que dicta el número de períodos en cada temporada.

El núcleo del modelo se fundamenta en un sistema de ecuaciones. En primera instancia, la estimación base aísla el impacto de las variables externas mediante una ecuación de regresión lineal:

$$y_t = \sum_{i=1}^k \beta_i X_{i,t} + u_t$$

Donde las ventas o la variable objetivo y_t dependen de las variables exógenas X_t ponderadas por sus coeficientes β , más un término de error residual u_t . Este error no es un ruido aleatorio simple, sino que contiene la estacionalidad y la tendencia histórica, el cual se transforma mediante la metodología de Box-Jenkins y la ecuación central SARIMA.

Durante la fase de estimación, el algoritmo busca los coeficientes óptimos asumiendo que los errores siguen una distribución normal con media 0 y varianza constante. A través de un método iterativo de optimización numérica por Máxima Verosimilitud, se maximiza la función de Log-Verosimilitud:

$$l(\Theta) = -\frac{T}{2} \ln(2\pi) - \frac{T}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{t=1}^T e_t^2$$

Finalmente, en la etapa de proyección, el modelo ensambla los coeficientes validados hacia el futuro. La estimación proyectada para un periodo $T+h$ se define matemáticamente como:

$$\hat{Y}_{T+h|T} = \sum_{i=1}^k \hat{\beta}_i X_{i,T+h} + \hat{u}_{T+h|T}$$

Esta predicción se construye sumando el componente exógeno, el impacto de las variables externas proyectadas, y el componente de memoria estocástica calculado por el proceso autorregresivo.

Entrenamiento Algorítmico y Transformaciones. El marco de entrenamiento se definió utilizando el histórico operativo comprendido entre enero del año dos mil veinticuatro y el último día de marzo del dos mil veintiséis, reservando la totalidad del mes de abril del dos mil veintiséis como conjunto de datos de prueba para evaluar la asertividad del pronóstico.

La calibración de la arquitectura se ejecutó de forma iterativa y metódica. Durante las configuraciones iniciales, la inclusión de una variable lógica para los días no laborables combinada con un orden estacional semanal generó colinealidad estructural, provocando inestabilidad en la matriz de covarianza del modelo. Al purgar este regresor redundante y eliminar el componente puro de media móvil, el cual carecía de significancia estadística real el algoritmo logró estabilizar satisfactoriamente la memoria autorregresiva de corto plazo.

No obstante, el motor de cálculo seguía arrojando advertencias sobre matrices singulares derivado de la colosal disparidad de escalas numéricas entre los indicadores binarios exógenos y la variable objetivo expresada en

millones de pesos. Para asegurar una convergencia absoluta, se aplicó una transformación de escalado sobre el vector de ventas, dividiendo cada registro entre un millón. Esta nivelación de magnitudes permitió al algoritmo de optimización numérica iterativa calcular los coeficientes óptimos con la máxima precisión matemática posible, apoyado por el método de estimación de máxima verosimilitud.

Evaluación de Métricas y Ajustes. La versión definitiva del modelo convergió bajo un orden general uno, cero, cero y un orden estacional uno, cero, uno, siete. Bajo esta estructura, las variables comerciales de intervención temporal, cierre de mes y zona límite mensual, arrojaron niveles de significancia perfectos, demostrando su altísima capacidad de impacto sobre la facturación.

La sanidad matemática del sistema fue ratificada mediante el análisis del componente estocástico. A través de la prueba formal de Ljung-Box, se comprobó la hipótesis nula que dictamina que los residuos se distribuyen de manera independiente. Esto garantiza que el error remanente del modelo es simple ruido blanco y valida la integridad predictiva del diseño estadístico.

Al someter el modelo entrenado sobre los datos reales del mes de abril, el comportamiento macroeconómico resultó sumamente preciso. La facturación real de la organización cerró en 34.29 millones de pesos, mientras que la proyección generada por el algoritmo anticipó un flujo de 35.20 millones de pesos. Este nivel de calibración se traduce en un desfase acumulado menor a un millón de pesos, equivalente a un margen de error total porcentual de apenas 2.64 % mensual y un error absoluto medio porcentual ponderado, onocido universalmente como WMAPE, de 27.30 % sobre la alta variabilidad diaria.

Implementación en el Pipeline. La instanciación y ejecución del flujo analítico se encapsuló en el directorio de notebooks del proyecto. El notebook en general recupera la matriz maestra de características, ejecuta el escalamiento numérico, entrena el objeto estadístico y persiste sus parámetros óptimos, junto con el análisis de los criterios de información, dentro de un diccionario serializado para su futura recuperación en despliegues productivos.

notebooks/sarimax.ipynb

```
1
2 master = pd.read_csv(f'{DATA_DIR}/master.csv')
3 y_scaled = master['net_price'] / 1_000_000
4 X = master[['is_month_end', 'close_month_zone']]
5
6 y_scaled.index = pd.to_datetime(master['sale_date'])
7 X.index = pd.to_datetime(master['sale_date'])
8
9 y_train_up_to_april = y_scaled[:'2026-04-30']
```



```

10 X_train_up_to_april = X[:'2026-04-30']
11
12 order_final = (1, 0, 0)
13 seasonal_order_final = (1, 0, 1, 7)
14
15 model_final = SARIMAX(
16     y_train_up_to_april,
17     exog=X_train_up_to_april,
18     order=order_final,
19     seasonal_order=seasonal_order_final,
20     enforce_stationarity=False,
21     enforce_invertibility=False
22 )
23
24 fit_res_final = model_final.fit(dispatch=False)
25
26 meta_final = save_metadata(
27     order=list(order_final),
28     seasonal_order=list(seasonal_order_final),
29     fit_obj=fit_res_final,
30     file_path=f'{MODELS_DIR}/sarimax_production.json'
31 )
32

```

Listing 19: Entrenamiento, escalado y proyección del modelo estadístico final.




Figura 9: Comparativa del total acumulado pronosticado versus la facturación real del mes de evaluación.




Figura 10: Trayectoria predictiva diaria demostrando la adaptación del modelo sobre las variaciones comerciales con intervalos de confianza del noventa y cinco por ciento.

Prophet

Entrenamiento e Implementación. A diferencia de los enfoques estadísticos clásicos basados en procesos autorregresivos, Prophet es un modelo aditivo desarrollado para el análisis de curvas de crecimiento. Su arquitectura no asume relaciones lineales estrictas ni estacionariedad, sino que descompone la serie temporal modelando la tendencia como una curva flexible, a la cual se le superponen efectos estacionales y días festivos de manera independiente. Esta flexibilidad intrínseca permite que el modelo sea considerablemente más tolerante a la varianza dispersa y a la falta de homogeneidad en los datos.

Para instrumentar este algoritmo dentro del entorno de desarrollo interactivo, el pipeline de preparación difiere estructuralmente de su predecesor. Prophet exige un mapeo explícito de columnas, demandando que la variable temporal sea renombrada como *ds* y el valor numérico objetivo como *y*.

El flujo operativo inició con la recuperación de la matriz maestra y la segmentación cronológica correspondiente. Tras definir el horizonte de entrenamiento hasta marzo del dos mil veintiséis, se construyó el conjunto de datos estandarizado y se instanció el objeto predictivo, forzando la detección exclusiva de estacionalidad semanal. Las variables de intervención temporal se añadieron al núcleo del modelo como regresores independientes antes de invocar la rutina de ajuste a los datos históricos.

```

1 train_cutoff = '2026-03-31'
2 master = pd.read_csv(f'{DATA_DIR}/master.csv')
3
4 y_train = master['net_price'][:train_cutoff]
5 X_train = master[['is_month_end', 'close_month_zone'
6                  ]][:train_cutoff]
```

```

7         df_prophet_train = pd.DataFrame({
8             'ds': pd.to_datetime(master['sale_date'][:
train_cutoff]),
9             'y': y_train.values,
10            'is_month_end': X_train['is_month_end'].values,
11            'close_month_zone': X_train['close_month_zone'].
values
12        })
13
14        p = Prophet(
15            yearly_seasonality=False,
16            weekly_seasonality=True,
17            daily_seasonality=False,
18            interval_width=0.95
19        )
20
21        p.add_regressor('is_month_end')
22        p.add_regressor('close_month_zone')
23
24        p.fit(df_prophet_train)
25

```

Listing 20: Inicialización del modelo aditivo Prophet y ajuste sobre datos de entrenamiento.

Construcción del Vector de Predicción. Para efectuar el cálculo hacia el horizonte futuro correspondiente a abril del dos mil veintiséis, fue necesario generar un vector de predicción independiente. Mediante una rutina de iteración temporal, se construyó un calendario que identificó los días laborales y reconstruyó dinámicamente las banderas operativas de la organización, inyectándolas en el motor de proyección para generar el pronóstico base junto con sus intervalos de confianza superior e inferior.

```

1         fechas_futuras = pd.date_range(start="2026-04-01", end=
"2026-04-30", freq='D')
2         df_exog_futuro = pd.DataFrame(index=fechas_futuras)
3
4         feriados_urvet_2026 = ['2026-04-02', '2026-04-03', '
2026-05-01']
5         df_exog_futuro['non_work_day'] = df_exog_futuro.index.
strftime('%Y-%m-%d').isin(feriados_urvet_2026).astype(int)
6
7         is_weekend = df_exog_futuro.index.weekday.isin([5, 6])
8         df_exog_futuro['is_workday'] = ~(is_weekend | (
df_exog_futuro['non_work_day'] == 1))
9
10        df_exog_futuro['is_month_end'] = 0
11        df_exog_futuro['close_month_zone'] = 0
12
13        for period, group in df_exog_futuro.groupby(
df_exog_futuro.index.to_period('M')):
14            work_days_month = group[group['is_workday']].index

```

```

15         if len(work_days_month) >= 1:
16             df_exog_futuro.loc[work_days_month[-1], '
is_month_end'] = 1
17         if len(work_days_month) >= 3:
18             df_exog_futuro.loc[work_days_month[-3:-1], '
close_month_zone'] = 1
19         elif len(work_days_month) == 2:
20             df_exog_futuro.loc[work_days_month[0], '
close_month_zone'] = 1
21
22         df_prophet_futuro = df_exog_futuro.reset_index().rename
(columns={'index': 'ds'})
23         df_prophet_futuro = df_prophet_futuro[['ds', '
is_month_end', 'close_month_zone']]
24
25         forecast_prophet = p.predict(df_prophet_futuro)
26         predicciones_limpias = forecast_prophet[['ds', 'yhat',
'yhat_lower', 'yhat_upper']]
27

```

Listing 21: Generación del calendario futuro y proyección de la demanda con Prophet.

Evaluación de Métricas y Ajustes. Al evaluar el desempeño de la arquitectura aditiva contra el flujo de ventas real de la organización, los resultados expusieron una dicotomía predictiva interesante. A nivel consolidado mensual, el algoritmo calculó un volumen de 34.97 millones de pesos frente a los 34.29 millones operados por la empresa, logrando un diferencial neto sumamente bajo de apenas 1.99% respecto al ingreso corporativo total.

Sin embargo, esta precisión macroscópica contrasta fuertemente con la asertividad microscópica diaria. Al calcular el error absoluto medio porcentual ponderado sobre la granularidad diaria, la arquitectura Prophet registró un 34.99% de desfase de ruta, lo que indica que si bien el modelo entiende y replica el volumen total del ecosistema de manera excelente, su capacidad para acertar el día exacto en que ocurrirá dicho volumen es deficiente en comparación con las arquitecturas lineales clásicas.




Figura 11: Trayectoria predictiva del modelo aditivo Prophet con su intervalo de confianza probabilístico.

LSTM

Desglose Matemático. Las Redes Neuronales Recurrentes LSTM (Long Short-Term Memory) mitigan el problema de pérdida de información de las RNN clásicas mediante una arquitectura diseñada para preservar o desechar selectivamente datos relevantes a lo largo de extensos instantes de tiempo. El procesamiento de una celda recurrente LSTM requiere la entrada actual x_t , el Estado Oculto anterior h_{t-1} , o denotado como a_{t-1} en algunas arquitecturas, e incorpora una dimensión extra de memoria de largo plazo: la Celda de Estado c_t .

El flujo de información se regula meticulosamente a través de compuertas construidas con funciones sigmoidales (σ) que actúan como filtros, permitiendo o bloqueando el paso de gradientes. El desdoblamiento matemático opera en cuatro fases principales:

- Compuerta de Olvido *Forget Gate*.
Determina la proporción de información histórica que será desecheda de la Celda de Estado.

$$f_t = \sigma(W_f[a_{t-1}, x_t] + b_f)$$

- Compuerta de Entrada *Input Gate* y Valores Candidatos.
Evalúa qué nueva información de la entrada actual merece ser almacenada en la memoria.

$$u_t = \sigma(W_i[a_{t-1}, x_t] + b_i)$$

Simultáneamente, se genera un vector de valores candidatos $\tilde{c}_t$ utilizando una función tangente hiperbólica para forzar una escala normalizada:

$$\tilde{c}_t = \tanh(W_c[a_{t-1}, x_t] + b_c)$$

- Actualización de la Celda de Estado.

La memoria interna se reescribe multiplicando el valor anterior por el filtro de olvido, y sumando los nuevos candidatos ponderados por la compuerta de entrada:

$$c_t = f_t \odot c_{t-1} + u_t \odot \tilde{c}_t$$

- Compuerta de Salida *Output Gate* y Nuevo Estado Oculto.

Define qué fracciones de la Celda de Estado actualizada formarán la salida inmediata de la neurona:

$$o_t = \sigma(W_o[a_{t-1}, x_t] + b_o)$$

El nuevo Estado Oculto se materializa al filtrar la Celda de Estado a través de una función tanh:

$$h_t = o_t \odot \tanh[c_t]$$

- Ecuación de la Predicción Final.

Como conclusión de la iteración temporal, el Estado Oculto obtenido se somete a una proyección lineal final para arrojar la predicción de la red en ese instante temporal específico:

$$\hat{y}_t = W_y h_t + b_y$$

Entrenamiento. La arquitectura de memoria a corto y largo plazo, se instanció bajo un diseño secuencial profundo. La estructura base se conformó por dos capas recurrentes equipadas con cincuenta neuronas cada una, empleando la función de activación rectificadora lineal unitaria para procesar las señales no lineales de la demanda.

Con el propósito de mitigar el riesgo de sobreajuste computacional se intercalaron capas de abandono aleatorio configuradas para apagar el veinte por ciento de las sinapsis durante cada ciclo de aprendizaje. El ensamblaje culminó con una neurona densa de salida lineal. Posteriormente, el motor se compiló utilizando el algoritmo de estimación adaptativa Adam para minimizar el error cuadrático medio, ejecutando el entrenamiento a lo largo de veinticinco iteraciones completas. Resultó imperativo desactivar el mezclado aleatorio de los lotes de datos para preservar la estricta cronología de la serie temporal.

```

1  model = Sequential()
2
3  model.add(LSTM(units=50, activation='relu',
4               return_sequences=True,
5               input_shape=(X_train_lstm.shape[1],
6                             X_train_lstm.shape[2])))
7  model.add(Dropout(0.2))

```

```

6
7     model.add(LSTM(units=50, activation='relu'))
8     model.add(Dropout(0.2))
9
10    model.add(Dense(units=1))
11
12    model.compile(optimizer='adam', loss='mse')
13
14    history = model.fit(
15        X_train_lstm,
16        y_train_scaled,
17        epochs=25,
18        batch_size=32,
19        validation_data=(X_test_lstm, y_test_scaled),
20        verbose=1,
21        shuffle=False
22    )
23

```

Listing 22: Arquitectura secuencial y entrenamiento de la red neuronal LSTM.




Figura 12: Curva de convergencia del error cuadrático medio durante las iteraciones de entrenamiento.

Evaluación de Métricas y Análisis Comparativo. La curva de aprendizaje demostró un comportamiento estable, evidenciando que las pérdidas de entrenamiento y validación descendieron armónicamente hasta estabilizarse cerca del origen numérico, lo cual confirma que el modelo asimiló la matemática de los datos sin caer en memorización pura.

Al proyectar las ventas del mes de abril y revertir el escalado matricial, el algoritmo calculó un volumen total de 29.35 millones de pesos, frente a los 34.29 millones facturados en la realidad operativa. Esta brecha de 4.94 millones se traduce en un déficit macroscópico del 14.41 % para el cierre mensual.

En cuanto a la precisión microscópica, la red neuronal alcanzó un error absoluto medio porcentual ponderado del 30.64 % por ciento sobre la variabilidad diaria. Al contrastar este indicador contra las arquitecturas previas, el desempeño del aprendizaje profundo se sitúa en un punto intermedio. Supera contundentemente la asertividad diaria del modelo aditivo Prophet, el cual registró un 34.9 %, pero se queda por detrás del 27.3 % por ciento logrado por el enfoque clásico SARIMAX.

Interpretación Analítica del Desempeño. La subestimación del volumen mensual es un fenómeno característico de las redes neuronales profundas cuando operan sobre conjuntos de datos restringidos. Al disponer de un histórico de transacciones inferior a mil registros diarios, la red logró mapear de forma excelente la morfología general de las fluctuaciones comerciales como los valles de fin de semana y las recuperaciones de mitad de semana, pero careció de la densidad de ejemplos necesaria para dimensionar la agresividad financiera de los cierres de mes.

Al integrar penalizaciones de abandono aleatorio para evitar el sobreajuste, la arquitectura optó por una proyección estadísticamente conservadora. En contraste, el modelo SARIMAX sumó el impacto de los regresores exógenos de manera directa y rígida sobre su línea base, permitiéndole alcanzar los techos históricos de facturación masiva con mayor precisión bajo escenarios de escasez de datos.




Figura 13: Trayectoria predictiva de la red neuronal LSTM frente al comportamiento real del mercado.

KNN

Desglose Matemático y Complejidad Computacional. El algoritmo de vecinos más cercanos es un método de aprendizaje supervisado de naturaleza no paramétrica. A diferencia de las arquitecturas estadísticas que optimizan una matriz de pesos globales durante el entrenamiento, este algoritmo pertenece a la categoría de aprendizaje perezoso o *lazy learning*.

Su mecanismo fundamental no construye un modelo interno precalculado, sino que memoriza la totalidad del conjunto de datos espaciales y pospone el esfuerzo de cálculo hasta el momento exacto en que se solicita una nueva inferencia.

El núcleo matemático del algoritmo reside en la evaluación de similitud geométrica mediante métricas de distancia en un espacio multidimensional. Dada una nueva observación y un registro histórico, la separación espacial entre ambos vectores se calcula predominantemente utilizando la norma euclidiana, la cual se encuentra formulada bajo la siguiente expresión matemática:

$$d_{q,i} = \sqrt{\sum_{j=1}^D (x_{q,j} - x_{i,j})^2}$$

donde D representa el número total de características predictivas. Una vez computadas las distancias de la nueva observación hacia todos y cada uno de los registros del conjunto maestro, el algoritmo aísla el subconjunto de los k puntos históricos que presenten la menor magnitud escalar.

Para resolver la variable objetivo, el sistema aplica un criterio de consolidación dependiente de la naturaleza del problema. En escenarios de clasificación categórica, la proyección se define mediante una votación de mayoría simple sobre las etiquetas de los vecinos aislados, modelada a través de una función indicadora:

$$\hat{y} = \operatorname{argmax}_{v \in V} \sum_{i=1}^k I_{y_i=v}$$

Por otro lado, cuando la variable objetivo es de carácter numérico continuo, como sucede en las proyecciones financieras de ventas netas, el valor proyectado se determina calculando el promedio aritmético puro o ponderado por distancia de las variables dependientes del vecindario más próximo:

$$\hat{y} = \frac{1}{k} \sum_{i=1}^k y_i$$

El diseño metodológico de esta arquitectura conlleva un perfil de complejidad computacional marcadamente atípico. La fase de entrenamiento presenta un costo de tiempo constante, dado que la operación se limita estrictamente a almacenar las estructuras matriciales en la memoria del sistema. En contraste absoluto, la exigencia de procesamiento recae íntegramente sobre la fase de predicción en producción. Para emitir un solo pronóstico, el motor debe evaluar la métrica de distancia contra el total de N registros históricos a través de sus correspondientes D dimensiones, requiriendo posteriormente un proceso de ordenamiento interno para extraer los elementos más cercanos.

Consecuentemente, el costo de inferencia por cada registro evaluado escala de forma proporcional al producto del volumen de datos por el número de variables, sumado al tiempo de ordenamiento algorítmico. Esto se expresa bajo una complejidad temporal asintótica *Big O* equivalente a

$$O(N \times D + N \log k)$$

De manera paralela, la complejidad espacial exige un almacenamiento persistente proporcional a

$$O(N \times D)$$

, lo cual representa un desafío operativo crítico y una demanda severa de memoria de acceso aleatorio cuando el sistema se implementa sobre bases de datos transaccionales de alto volumen.

Implementación. A continuación se expone el bloque de código estructurado en el entorno de desarrollo para validar la mecánica interna del algoritmo, enfrentando la rutina de cálculo de distancias por fuerza bruta contra el motor de ejecución automatizado:

```

1 import time
2 import numpy as np
3 import pandas as pd
4 from sklearn.neighbors import KNeighborsClassifier
5 from sklearn.metrics import accuracy_score
6
7
8 def euclidean_distance(row1, row2):
9     return np.sqrt(np.sum((row1 - row2) ** 2))
10
11 def get_neighbors(train_X, train_y, test_row, num_neighbors):
12     distances = []
13     for i in range(len(train_X)):
14         dist = euclidean_distance(test_row, train_X[i])
15         distances.append((train_y[i], dist))
16     distances.sort(key=lambda tup: tup[1])
17     neighbors = []
18     for i in range(num_neighbors):
19         neighbors.append(distances[i][0])
20     return neighbors
21
22 def predict_classification_manual(train_X, train_y, test_row,
23                                 num_neighbors):
24     neighbors = get_neighbors(train_X, train_y, test_row,
25                               num_neighbors)
26     output_values = [row for row in neighbors]
27     prediction = max(set(output_values), key=output_values.
28                       count)
29     return prediction
30
31 start_manual = time.time()

```

```

29
30 end_manual = time.time()
31 time_manual = end_manual - start_manual
32
33
34 start_sklearn = time.time()
35 clf = KNeighborsClassifier(n_neighbors=5, algorithm='auto')
36
37 clf.fit(X_train_kn, y_train_kn)
38 pred_sklearn = clf.predict(X_test_kn)
39 end_sklearn = time.time()
40 time_sklearn = end_sklearn - start_sklearn
41
42 print(f"Tiempo de ejecucion manual: {time_manual:.3f} segundos"
43       )
44 print(f"Tiempo de ejecucion optimizado: {time_sklearn:.3f}
45       segundos")

```

Listing 23: Diseño del clasificador KNN manual versus la optimización de scikit-learn.

Entrenamiento. Debido a la naturaleza del algoritmo de vecinos más cercanos como un aprendiz perezoso, la fase de ajuste no genera una optimización paramétrica previa, sino que se limita a la indexación y almacenamiento de los vectores en el espacio dimensional. El verdadero costo computacional se desplaza hacia la etapa de evaluación de instancias, la cual se ejecutó mediante un esquema de validación cruzada de cinco pliegues sobre el perfil de comportamiento de los clientes, considerando dimensiones estructurales como la recencia, la frecuencia y el valor monetario para predecir si un consumidor consolidará un alto valor comercial.

La implementación construida desde cero arrojó una precisión promedio del 95.208 por ciento en la clasificación de los registros. No obstante, el costo temporal de la ejecución manual ascendió a un total de 33.648 segundos. Este rezago operativo responde a que la rutina realiza ciclos explícitos y comparaciones iterativas en un entorno no compilado para resolver las distancias de cada pliegue de prueba contra el conjunto de entrenamiento, reflejando un comportamiento empírico y asintótico complejo de orden

$$O(n^2 \cdot d)$$

cuando el volumen de muestras y sus dimensiones escalan de forma proporcional.

Comparación con Librerías Estándar. Con la finalidad de validar la eficiencia operativa del desarrollo manual, se contrastaron sus métricas y tiempos frente a la implementación de referencia provista por la biblioteca scikit-learn. El estimador automatizado reportó una precisión media del

94.709 por ciento, un valor estadísticamente equivalente al desempeño del código propio.

La divergencia crítica entre ambos entornos radica en la velocidad de procesamiento durante la fase de inferencia. Mientras que la rutina nativa demanda decenas de segundos para concluir las clasificaciones, el módulo optimizado resuelve la totalidad de las predicciones en apenas 0.018 segundos. Esta aceleración asintótica extrema ocurre porque la librería estándar evade la estrategia de fuerza bruta mediante el parámetro de selección automática de algoritmos, estructurando los datos en árboles de búsqueda binaria indexados que optimizan drásticamente la localización de los vecinos más próximos y reducen la complejidad temporal de la predicción, evitando el cálculo exhaustivo de distancias contra la totalidad de la base transaccional.




Figura 14: Curva comparativa de rendimiento temporal asintótico entre la rutina de código propio y el motor optimizado.

Regresión Logística

Desglose Matemático y Complejidad Computacional. El modelo de regresión logística constituye un algoritmo de aprendizaje supervisado fundamental dentro del ámbito del aprendizaje automatizado, diseñado específicamente para resolver problemas de clasificación donde el resultado esperado es de naturaleza discreta o categórica. El principio operativo de esta arquitectura radica en estimar la probabilidad de ocurrencia de una clase determinada mediante el empleo de la función logística estándar, también conocida como función sigmoide, la cual comprime cualquier valor de entrada numérico continuo hacia un rango estrictamente acotado entre cero

y uno. La expresión matemática que rige esta transformación se define como:

$$P(y = 1|x) = \frac{1}{1 + e^{-z}}$$

donde el componente z representa la combinación lineal de las características del vector de entrada ponderadas por sus respectivos coeficientes de peso, incorporando además un término de sesgo o intersección con el eje. Para optimizar estos coeficientes y reducir el error de clasificación de forma progresiva, el algoritmo recurre al método de descenso de gradiente estocástico. En cada iteración sobre el conjunto de datos, las magnitudes de los pesos se actualizan fila por fila de forma iterativa utilizando una tasa de aprendizaje constante que multiplica al error obtenido y al gradiente de la propia función sigmoide, modelando las reglas de ajuste mediante las siguientes ecuaciones secuenciales:

$$\begin{aligned}\beta_0 &= \beta_0 + \alpha \cdot (y - \hat{y}) \cdot \hat{y} \cdot (1 - \hat{y}) \\ \beta_j &= \beta_j + \alpha \cdot (y - \hat{y}) \cdot \hat{y} \cdot (1 - \hat{y}) \cdot x_j\end{aligned}$$

En este esquema analítico, el término α denota la tasa de aprendizaje establecida, la variable y corresponde al valor real de la etiqueta de clase, el componente $\hat{y}$ representa la probabilidad predicha por el sistema y la diferencia entre ambos constituye el error residual local. En lo relativo al costo computacional de la arquitectura, la complejidad temporal requerida durante la etapa de ajuste escala de manera del todo proporcional al tamaño de la muestra, el número de variables explicativas y el volumen total de épocas programadas, quedando acotada asintóticamente bajo un orden de magnitud equivalente a

$$O(n \cdot d \cdot i)$$

Implementación. Con el objetivo de validar los fundamentos algebraicos del modelo sin depender de abstracciones externas, se desarrolló una rutina de programación nativa en el entorno de desarrollo que implementa el motor de predicción y el bucle de optimización transaccional mediante funciones de control iterativas. La estructura del código fuente de esta solución manual se expone a continuación:

```
1  import numpy as np
2
3  def predict(row, coefficients):
4      yhat = coefficients[0]
5      for i in range(len(row) - 1):
6          yhat += coefficients[i + 1] * row[i]
7      return 1.0 / (1.0 + np.exp(-yhat))
8
9  def coefficients_sgd(train, l_rate, n_epoch):
10     coef = [0.0 for i in range(len(train[0]))]
```

```

11         for epoch in range(n_epoch):
12             for row in train:
13                 yhat = predict(row, coef)
14                 error = row[-1] - yhat
15                 coef[0] = coef[0] + l_rate * error * yhat * (1.0 -
yhat)
16                 for i in range(len(row) - 1):
17                     coef[i + 1] = coef[i + 1] + l_rate * error *
yhat * (1.0 - yhat) * row[i]
18             return coef
19
20     def logistic_regression(
21         train,
22         test,
23         l_rate,
24         n_epoch
25     ):
26
27         predictions = list()
28
29         coef = coefficients_sgd(
30             train,
31             l_rate,
32             n_epoch
33         )
34
35         for row in test:
36
37             yhat = predict(
38                 row,
39                 coef
40             )
41
42             yhat = round(yhat)
43
44             predictions.append(
45                 yhat
46             )
47
48         return predictions
49

```

Listing 24: Implementación manual del algoritmo de regresión logística mediante descenso de gradiente estocástico.

Entrenamiento. La fase de experimentación y ajuste de los coeficientes del modelo se llevó a cabo utilizando una estrategia de validación cruzada estructurada en cinco pliegues analíticos, garantizando que cada segmento de la base de datos fungiera como conjunto de prueba de manera rotativa. Durante este proceso, las funciones optimizaron los pesos de forma secuencial a lo largo de las épocas establecidas, registrando una convergencia estable

del error general hacia valores mínimos y logrando una precisión media en la clasificación de los registros equivalente al 93.137 por ciento de asertividad global.

Comparación con Librerías Estándar. Para auditar la viabilidad operativa y el rendimiento de la rutina manual, se enfrentaron sus resultados y tiempos de procesamiento de datos contra el estimador altamente optimizado de la biblioteca scikit-learn. En términos de capacidad predictiva, ambos entornos demostraron una simetría absoluta, alcanzando un nivel idéntico de precisión del 93.137 por ciento sobre el conjunto de datos evaluado.

La diferencia crítica se manifiesta de forma radical en el costo temporal del procesamiento informático. Mientras que la rutina propia requiere un lapso de 14.523 segundos para concluir los ciclos iterativos de optimización debido a la ejecución secuencial en un entorno interpretado, el motor automatizado de la librería estándar resuelve todo el proceso de ajuste en apenas 0.004 segundos. Esta disparidad temporal extrema se debe a que las paqueterías comerciales ejecutan sus operaciones de álgebra lineal mediante subrutinas compiladas de bajo nivel y optimizaciones de memoria matricial vectorizada, anulando los cuellos de botella de los bucles explícitos, comportamiento que se documenta visualmente en la siguiente representación gráfica:




Figura 15: Evaluación comparativa del costo de tiempo de ejecución entre el descenso de gradiente estocástico manual y el motor vectorizado.

0.4. Resultados

Tras la ejecución del pipeline analítico y el entrenamiento de las arquitecturas predictivas sobre la matriz transaccional de Urvet de México, se obtuvieron métricas de rendimiento que permiten contrastar la viabilidad operativa de cada enfoque matemático.

0.4.1. Comparativa de Implementaciones

El análisis de las proyecciones para el mes de abril del dos mil veintiséis reveló comportamientos contrastantes entre los modelos estadísticos, aditivos y de aprendizaje profundo:

- **Modelo SARIMAX.**
Se consolidó como la arquitectura más equilibrada y asertiva. Logró un error absoluto medio porcentual ponderado del 27.3 % sobre la varianza diaria y un desfase macroscópico de apenas 2.64 % mensual. Su capacidad para asimilar las variables exógenas le permitió proyectar los picos de facturación masiva con extrema precisión geométrica.
- **Modelo Prophet.**
Demostró una asertividad macroscópica sobresaliente al predecir el volumen total mensual con un margen de error mínimo del 1.99 %. Sin embargo, su desempeño microscópico fue deficiente, registrando el error diario más alto con un 34.99 %. Esto indica que el algoritmo suaviza excesivamente la serie y falla al intentar ubicar el día exacto de las fluctuaciones comerciales.
- **Modelo LSTM.**
La red neuronal profunda exhibió un rendimiento intermedio en la escala diaria con un error del 30.64 %, pero falló significativamente en el acumulado mensual, subestimando la demanda real en un 14.41 %. Su comportamiento conservador derivó de la escasez relativa de datos históricos, impidiendo que los tensores asimilaran la agresividad financiera de los cierres operativos.

0.4.2. Hallazgos y Posibles Mejoras

El desarrollo del Proyecto JAPI expuso la naturaleza del mercado mayorista de Urvet, dictada en gran medida por el comportamiento de la fuerza de ventas corporativa más que por un consumo orgánico lineal. Las variables de intervención temporal específicamente la zona de cierre mensual demostraron ser el componente predictivo más valioso de todo el ecosistema de datos.

Para iteraciones futuras, se proponen tres vectores de mejora técnica: la expansión del corpus de entrenamiento para robustecer la arquitectura

LSTM integrando múltiples años de historia transaccional, la implementación de algoritmos de ensamble que promedien las estimaciones de SARI-MAX y Prophet para balancear la precisión diaria y mensual, y la optimización de hiperparámetros mediante búsquedas exhaustivas en mallas de validación.

0.5. Conclusiones

El propósito rector del Proyecto JAPI consistió en transformar los registros transaccionales crudos de Urvet de México en un activo estratégico de valor predictivo. Los resultados analíticos demuestran que la implementación formal de estas arquitecturas lideradas operativamente por el modelo SARIMAX es técnica y financieramente viable para el entorno de producción de la organización.

0.5.1. Propuesta de Valor e Implementación Operativa

El despliegue de este motor predictivo en el área logística y financiera de la empresa ofrece una ventaja competitiva sustentada en la anticipación matemática. Al contar con un pronóstico diario altamente preciso que mapea los picos de demanda inducidos por los cierres de mes, la organización adquiere la capacidad de optimizar la rotación de su inventario, previniendo el desabasto de productos farmacéuticos y biológicos veterinarios durante las jornadas de mayor presión comercial.

A nivel estratégico, la adopción de este sistema analítico permite transicionar de un modelo de reabastecimiento reactivo hacia una gestión proactiva de la cadena de suministro. Este avance metodológico no solo mitiga el riesgo de capital inmovilizado en sobreinventarios durante los valles de demanda semanal, sino que estabiliza la planificación del flujo de efectivo, consolidando a la inteligencia artificial y a la ciencia de datos como pilares operativos irremplazables para el crecimiento sostenible de la empresa.

Bibliografía

- [1] Amat Rodrigo, J. (s. f.). *Modelos ARIMA y SARIMAX con Python*. Ciencia de Datos. <https://cienciadedatos.net/documentos/py51-modelos-arima-sarimax-python>
- [2] Ecevit, A., Öztürk, İ., Dağ, M., & Özcan, T. (2023). Short-term sales forecasting using LSTM and Prophet based models in e-commerce. *Acta Infologica*, 7(1), 59–70. <https://doi.org/10.26650/acin.1259067>
- [3] Fonseca, M. (s. f.). *Notas de clase: Series de tiempo*. Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas (IIMAS), UNAM. http://www.dpye.iimas.unam.mx/miguel/st_CNSF/notas_28_junio.pdf
- [4] González E. (s. f.). *Análisis de series de tiempo* [Documento de RPub]. RPub. <https://rpubs.com/ElianElian/1171469>
- [5] IBM. (s. f.). *¿Qué son las redes neuronales recurrentes?*. IBM Think. <https://www.ibm.com/mx-es/think/topics/recurrent-neural-networks>
- [6] Prophet. (s. f.). *Quick Start*. Recuperado el 18 de mayo de 2026 de https://facebook.github.io/prophet/docs/quick_start.html#python-api
- [7] Prophet Project. (2026, 2 de febrero). *Quick start*. Prophet Documentation. https://facebook.github.io/prophet/docs/quick_start.html
- [8] Psycopg. (s. f.). *Basic module usage*. Recuperado el 18 de mayo de 2026 de <https://www.psycopg.org/docs/usage.html#passing-parameters-to-sql-queries>
- [9] Python Package Index. (s. f.). *sshtunnel*. Recuperado el 18 de mayo de 2026 de <https://pypi.org/project/sshtunnel/>
- [10] Seaborn. (s. f.). *seaborn.boxplot*. Recuperado el 18 de mayo de 2026 de <https://seaborn.pydata.org/generated/seaborn.boxplot.html>

- [11] Sotaquirá, M. (s. f.). *La función de activación en las Redes Neuronales*. Codificando Bits. <https://codificandobits.com/blog/funcion-de-activacion/>
- [12] Sotaquirá, M. (s. f.). *Redes LSTM: Introducción práctica*. Codificando Bits. <https://codificandobits.com/blog/redes-lstm/>
- [13] Statsmodels. (s. f.). *statsmodels.tsa.statespace.sarimax.SARIMAX*. Recuperado el 18 de mayo de 2026 de <https://www.statsmodels.org/dev/generated/statsmodels.tsa.statespace.sarimax.SARIMAX.html>
- [14] Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37–45. <https://peerj.com/preprints/3190/>
- [15] TensorFlow. (s. f.). *tf.keras.layers.LSTM*. Recuperado el 18 de mayo de 2026 de https://www.tensorflow.org/api_docs/python/tf/keras/layers/LSTM
- [16] Toledano, I. [IvTole]. (s. f.). *MachineLearning-InferenciaBayesiana_CUGDL* [Repositorio de GitHub]. GitHub. https://github.com/IvTole/MachineLearning-InferenciaBayesiana_CUGDL/tree/main