



Introducción

El entorno competitivo actual en el sector comercial exige que las organizaciones adopten enfoques analíticos avanzados para optimizar la toma de decisiones estratégicas, particularmente en la gestión de inventarios y la planificación financiera. En este contexto se sitúa Urvet de México, una organización dedicada a la distribución mayorista de productos farmacéuticos, biológicos, alimenticios y accesorios especializados para el sector veterinario y de la salud animal. Su operación comercial abarca una compleja red de suministro que atiende a clínicas, hospitales veterinarios y centros de distribución minoristas. Esta dinámica comercial genera un flujo constante de datos transaccionales con un alto potencial de explotación para el desarrollo de ventas competitivas. Con el propósito de transformar este activo analítico en valor predictivo, se ha diseñado el Proyecto JAPI, denominado así a partir de las iniciales de los integrantes del equipo de trabajo. El núcleo técnico de la investigación se centra en la incorporación, entrenamiento y evaluación comparativa de tres arquitecturas de modelado de series de tiempo de distinta naturaleza: el modelo estadístico lineal SARIMAX, el modelo aditivo Prophet, y la red neuronal recurrente LSTM. La variable objetivo fundamental para este análisis es la proyección de las ventas netas, definida estrictamente como las ventas totales de la organización tras deducir los descuentos comerciales y las devoluciones de producto, calculadas antes de la aplicación de cargas impositivas.

Objetivos

Objetivo General.

Desarrollar e implementar un sistema predictivo robusto para la proyección de ventas netas en Urvet mediante la evaluación comparativa de SARIMAX, Prophet y LSTM para determinar la arquitectura de mayor precisión.


Referencias

- Amat Rodrigo, J. (s.f.). *Ciencia de Datos*. <https://cienciadedatos.net>
- Ecevit, A., et al. (2023). *Acta Infologica*, 7(1), 59–70.
- Toledano, I. (s.f.). *GitHub Repository*. <https://github.com/lvTole>


Metodología

Adquisición y Modelado de Datos


Para la ingesta segura de datos desde PostgreSQL se desarrolló una clase en Python que gestiona un túnel cifrado SSH a través de un puerto local virtualizado. El preprocesamiento homogeneizó una matriz de 697,750 registros crudos a punto flotante de 64 bits. El análisis estadístico reveló una asimetría severa a la derecha (Media: \$1,292.18, Mediana: \$624.29, Máx: \$2,540,697.36), típica de la distribución mayorista. El hallazgo crítico fue la presencia de valores negativos extremos (-\$4.2M) correspondientes a notas de crédito y devoluciones, destacando una caída vertical en julio 2024 de -\$2.5M.



Para no corromper el aprendizaje de las redes neuronales ni romper la continuidad cronológica, se aislaron 18 días anómalos (< 2%) e imputaron mediante interpolación lineal geométrica, dió como resultado una distribución que si bien tiene solo valores atípicos positivos, estos realmente representan comportamiento comercial real.



Descomposición Temporal



Los datos limpios se ordenaron cronológicamente y se remuestrearon a una frecuencia diaria continua, consolidando una serie de 865 observaciones. Se aplicó un filtro de descomposición aditiva paramétrica que confirmó una fuerte estacionalidad semanal ($s = 7$), caracterizada por valles logísticos recurrentes de -\$750,000. La prueba de Dickey-Fuller Aumentada (ADF) arrojó un p -valor = 0.017, rechazando la hipótesis de raíz unitaria. No elegible de forma unidimensional, al contrastar el test con la tendencia visual se detectó una inercia ascendente prolongada en el último cuatrimestre. Para blindar el pipeline contra sesgos exponenciales, se determinó incorporar configuraciones de diferenciación integral (d) en el modelado estadístico.

Características Exógenas

El análisis del componente residual expuso varianzas intermitentes no explicadas por la tendencia, correlacionadas directamente con los picos de facturación masiva al cierre de los ciclos comerciales. Para capturar esta dinámica operativa sin suavizar artificialmente los picos reales de demanda limite, se construyó una matriz de características exógenas mediante banderas lógicas binarias (0 o 1). Se mapearon dos dimensiones clave:

- `is_month_end`: Jornada exacta de corte contable.
- `close_month_zone`: Ventana de los últimos 3 días del mes, donde se concentran las ventas de alto volumen.


Tabla 1: Matriz de variables de intervención exógenas filtrada.

sale_date	is_month_end	close_month_zone
2024-01-02	0	0
2024-01-03	0	0
2024-01-04	0	0
2024-01-05	0	0
2024-01-06	0	0
⋮	⋮	⋮
2026-03-27	0	1
2026-03-28	0	0
2026-03-29	0	0
2026-03-30	0	1
2026-03-31	1	0

Por último, en el caso de la red LSTM, que necesita lags, se le agregaron para seguir su metodología. estos lags actúan como características adicionales para que la red tenga memoria. Los lags incorporados fueron `lag_1` y `lag_7`. Esta matriz se concatenó lateralmente con la serie univariada, exportando un dataset maestro indexado (`master.csv`) que actuó como la fuente única de verdad para el entrenamiento de SARIMAX, Prophet y LSTM. para la evaluación de resultados, considerando que los modelos fueron entrenados hasta marzo 2026, se hizo una proyección mensual a granularidad diaria del mes de abril, ya que, si se cuentan con esos datos completos. Se evaluó el acumulado del error absoluto por cada predicción diaria, así como el acumulado real y el margen de error diario WMAPE. Para la cuestión mensual, Se sumaron las proyecciones diarias y las ventas diarias reales, a partir de ambas sumas se obtuvo el error mensual.


Resultados

Modelo SARIMAX




- Suma Real Total: \$34,292,377.81
- Suma Predicha Total: \$35,200,000.00
- Diferencia Absoluta: -\$907,622.19
- Diff. Porcentual Mensual: 2.64 %
- Error Acumulado: 9,362,452.60
- WMAPE Total: 27.30 %

Modelo Prophet



- Suma Real Total: \$34,292,377.81
- Suma Predicha Total: \$34,973,405.17
- Diferencia Absoluta: -\$681,027.36
- Diff. Porcentual Mensual: 1.99 %
- Error Acumulado: 11,999,998.15
- WMAPE Total: 34.99 %

Red Neuronal LSTM



- Suma Real Total: \$34,292,377.81
- Suma Predicha Total: \$29,350,216.00
- Diferencia Absoluta: \$4,942,161.81
- Diff. Porcentual Mensual: -14.41 %
- Error Acumulado: 10,506,205.29
- WMAPE Total: 30.64 %